

# Génération de peptides par pipeline agentique multi-experts

Encadrant : Akka Zemmari

## Contexte

Les peptides (par exemple les peptides antimicrobiens) constituent une famille de molécules candidates pour de nombreuses applications. Leur conception in silico repose souvent sur des boucles itératives combinant la génération de candidats, l'application de contraintes formelles et l'évaluation par des scores (activité attendue, toxicité, stabilité, etc.).

L'objectif de ce projet est de construire un prototype agentique (PoC) dans lequel plusieurs agents logiciels spécialisés coopèrent pour proposer, analyser et améliorer des peptides de manière itérative, avec une évaluation quantitative explicite des solutions produites.

Le projet est centré sur les aspects IA (modélisation, orchestration multi-agents, raisonnement, évaluation) et n'exige aucune connaissance préalable en biologie ou en chimie.

## Objectif

Développer une **pipeline agentique** (3 agents + orchestrateur) capable de :

- 1) générer des candidats peptides,
- 2) appliquer des **contraintes "chimie"** (validité / faisabilité proxy),
- 3) appliquer une **critique "bio"** (activité attendue + risques proxy),
- 4) itérer sur plusieurs rounds,
- 5) produire un **Top-K** final et montrer un **gain mesurable** vs une baseline non-agentique.

## Agents attendus (minimum)

- **Agent IA (Designer)** : propose des peptides (prompting + gabarits + opérateurs de mutation/croisement, etc.).
- **Agent Chimie (Constraints)** : vérifie/filtre selon des contraintes (longueur, charge nette, hydrophobicité, solubilité proxy, motifs interdits, etc.).
- **Agent Bio (Function/Risk)** : score/critique l'activité attendue + risques (ex. toxicité/hémolyse proxy) et propose des pistes d'amélioration.
- **Orchestrateur** : boucle d'itération (proposer → filtre → score → réviser), critères d'arrêt, traçabilité.

## Évaluation (obligatoire)

- Mettre en place au moins **un score quantitatif** basé sur :
  - un modèle léger (ML classique) entraîné sur données publiques **ou**
  - un ensemble de règles/heuristiques robustes,
  - éventuellement complété par des outils/embeddings pré-entraînés (bonus).
- Mesurer et rapporter :
  - validité (% peptides respectant les contraintes),
  - score moyen / score Top-K,
  - diversité (ex. distances/entropie/unique n-grams),
  - taux de passage des contraintes,
  - évolution des scores au fil des itérations,
  - comparaison avec une **baseline** (génération aléatoire / heuristique sans agents / sans itération).

## Livrables

- 1) Code propre (repo Git) + scripts reproductibles (seed, config).
- 2) Pipeline end-to-end + logs des itérations (traçabilité).
- 3) Rapport court (8–12 pages) : méthode, scores, résultats, ablations.
- 4) Démo : exécution d'un run + présentation du Top-K et de la trajectoire d'amélioration.

## Périmètre / Hypothèses

- Projet **in-silico uniquement** (pas de validation wet-lab).
- Les scores utilisés sont des **proxies** (prédictions) et doivent être clairement documentés.

## Bonus (si avance)

- Embeddings type ESM pour améliorer le scoring.
- Ablations complètes (sans agent chimie / sans agent bio / sans itération).
- Optimisation multi-objectif (Pareto : activité vs toxicité vs solubilité).
- Interface légère (Streamlit) pour visualiser la “discussion” et les itérations.